

DataMedX Hackathon 2 — Ön Değerlendirme Raporu

Onkoloji Veri Setinde Diyabet Yükü Analizi, Türkçe NLP ve Kanser Türü Sınıflandırması

Ahmet Erdem Pamuk^{*1}, Hamit Tuğrul Arslan², and Ömer Kay³

¹Mustafa Hakan Güvençer Fen Lisesi, Ankara

²İstanbul Teknik Üniversitesi Mesleki ve Teknik Anadolu Lisesi, İstanbul

³Özel Çağdaş Eğitim Anadolu Lisesi, İzmir

Takım: **CatBoost Baseline**

Nisan 2026

Özet

Bu çalışma, İstinye Üniversitesi tarafından düzenlenen DataMedX Hackathon 2 ön değerlendirme görevi kapsamında **CatBoost Baseline** takımı tarafından hazırlanmıştır. Beş farklı kanser türünden (karaciğer, meme, multipl miyelom, over, prostat) toplam 500 hastayı içeren ve hem laboratuvar değerleri hem de Türkçe epikriz metinleri barındıran veri seti üzerinde üç yönlü bir analiz gerçekleştirilmiştir: (i) HbA1c değerleri üzerinden ADA eşiklerine göre diyabet/prediyabet yükünün kanser türlerine göre dağılımı, (ii) epikriz metninden TF-IDF ile anahtar terim ve regex tabanlı semptom çıkarımı, (iii) yalnızca rutin laboratuvar ve demografik özelliklerle eğitilen iki temel makine öğrenmesi modeli (Lojistik Regresyon ve Rastgele Orman). Ki-kare testi, kanser türleri arasında HbA1c kategorilerinde istatistiksel olarak anlamlı bir fark bulunduğunu ($\chi^2=17.03$, $p=0.030$) göstermiştir. Rastgele Orman modeli, 5-katlı çapraz doğrulamada %71.2 doğruluk elde etmiş; bu, beş sınıflı görevde rastgele tahminin (%20) yaklaşık 3.5 katıdır. Tüm kod tabanı; her bir adım için ayrı ve *conventional commit* mesajlarıyla GitHub üzerinde yayımlanmıştır.

1 Giriş ve Problem Tanımı

DataMedX Hackathon 2 ön değerlendirme aşamasında bizden, paylaşılan veri seti üzerinde onkoloji, görüntü işleme veya doğal dil işleme alanlarından bir veya birkaçına yönelik basit bir uygulama, veri analizi ya da model önerisi geliştirmemiz beklenmiştir. Veri seti incelendiğinde; başlığın aksine yalnızca diyabet odaklı değil, **onkoloji ve diyabetin kesişiminde** yer alan, içinde HbA1c ölçümlerinin yanında klasik onkolojik laboratuvar paneli ve Türkçe epikriz metinleri bulunan zengin bir kaynakla karşılaştığımızı tespit ettik. Bu nedenle çalışmamızı tek bir alana sıkıştırmak yerine üç tamamlayıcı eksenle kurguladık:

1. **Klinik analiz:** Kanser türlerine göre diyabet ve prediyabet yükünün karşılaştırılması.
2. **Doğal dil işleme:** Türkçe epikriz metinlerinden anahtar terim ve semptom çıkarımı.
3. **Makine öğrenmesi:** Yalnızca rutin laboratuvar değerleri kullanılarak kanser türünün tahmin edilmesi.

Görev, *basit ama anlamlı* bir uygulama üretmek olarak tanımlanmıştır; bu çerçevede derin öğrenme veya hiper-parametre optimizasyonu gibi karmaşıklık katacak yaklaşımlardan bilinçli olarak kaçınılmış, açıklanabilir ve klinik olarak yorumlanabilir baseline'lar tercih edilmiştir.

^{*}Takım Kaptanı, ahmeterdempmk@gmail.com

2 Veri Seti

Veri seti, `datamedx_veriset_26.xlsx` dosyasında yer almakta; 500 satır ve 54 sütundan oluşmaktadır. Her bir kanser türünden 100 hasta bulunmakta, dolayısıyla sınıflar arasında mükemmel denge sağlanmaktadır. Tablo 1 veri setinin temel istatistiklerini özetlemektedir.

Tablo 1: Veri seti özet istatistikleri.

Özellik	Değer
Toplam hasta sayısı	500
Sütun sayısı	54
Kanser türü sayısı	5 (her biri 100 hasta)
Kadın / Erkek	291 / 209
Yaş ortalaması (medyan)	67.2 (69.0)
Lab parametre sayısı	17
HbA1c ölçümü mevcut	401 / 500 (%80.2)
Epikriz metni mevcut	500 / 500 (%100)

Veri setinin önemli bir özelliği, hücrelerin büyük bölümünün `[değer1]`, `[değer2]`, ... biçiminde çoklu zaman noktası içermesidir. Bu yapı, her hasta için aynı laboratuvar testinin farklı tarihlerde tekrarlandığı bir uzunlamasına izlemi temsil etmektedir. Bu nedenle ön işleme aşamasında, köşeli parantez içindeki tüm sayısal değerleri çıkaran, ortalama (`_mean`), son değer (`_last`) ve ölçüm sayısı (`_n`) özetlerini üreten bir *parser* katmanı geliştirilmiştir (`src/parse_utils.py`).


Diğer ön işleme adımları:

- `cinsiyet` sütunundan `[kadın]`/`[erkek]` etiketleri ayrıştırıldı.
- Yaş, `2026 - doğum yılı` formülüyle hesaplandı.
- Epikriz metnindeki `_x000D_` kaçış karakterleri ve fazla boşluklar temizlendi, küçük harfe çevrildi.
- `ölüm durumu` sütunu tamamen boş olduğundan analiz dışı bırakıldı.


3 Keşifsel Veri Analizi (EDA)

EDA aşamasında demografik dağılım, eksik değer haritası ve kilit laboratuvar değerlerinin kanser türlerine göre dağılımı incelenmiştir (Şekil 1).


Beklendiği üzere meme ve over kanseri kadın, prostat kanseri ise erkek hastalardan oluşmaktadır; karaciğer kanseri ve multipl miyelom her iki cinsiyette gözlenmektedir. Yaş dağılımında prostat kanseri (ortalama 75.2) en yaşlı, over kanseri (ortalama 61.3) en genç grubu oluşturmaktadır.




(a) Cinsiyet dağılımı.



(b) Yaş dağılımı.



(c) Laboratuvar eksiklik oranları.



(d) Kilit laboratuvar değerleri.

Şekil 1: Keşifsel veri analizi: demografi, eksiklik ve kanser türüne göre temel laboratuvar dağılımları.

4 HbA1c Üzerinden Diyabet Yükü Analizi

HbA1c, hem diyabet tanısı hem de uzun dönem glisemik kontrolün izlenmesinde kullanılan altın standart bir biyobelirteçtir. Amerikan Diyabet Derneği (ADA) eşiklerine göre değerler üç kategoriye ayrılır:

- **Normal:** $HbA1c < 5.7$
- **Prediyalet:** $5.7 \leq HbA1c < 6.5$
- **Diyabet:** $HbA1c \geq 6.5$

Her hasta için takip süresince ölçülen *en yüksek* HbA1c değeri esas alınmıştır; bu, diyabet riskini tespit etmede daha duyarlı bir yaklaşımdır. Tablo 2 ve Şekil 2 sonuçları özetlemektedir.


Tablo 2: Kanser türüne göre HbA1c kategorilerinin yüzde dağılımı.

Kanser türü	Normal	Prediyalet	Diyabet	Bilinmiyor
Karaciğer kanseri	%25	%20	%34	%21
Meme kanseri	%16	%32	%36	%16
Multipl miyelom	%20	%17	%27	%36
Over kanseri	%34	%31	%20	%15
Prostat kanseri	%22	%28	%39	%11

Beklenen ve gözlenen frekanslar üzerinde gerçekleştirilen Pearson ki-kare bağımsızlık testi, kanser türleri arasında HbA1c kategorilerinin dağılımında anlamlı bir farklılık olduğunu ortaya koymuştur:

$$\chi^2 = 17.03, \quad \text{dof} = 8, \quad p = 0.030.$$

Diyabet oranı en yüksek olan grup prostat kanseri (%39) iken, over kanseri (%20) en düşük orana sahiptir. Klinik perspektiften bu bulgu, prostat ve meme kanseri takibi yapan onkoloji birimlerinde



Şekil 2: Kanser türüne göre HbA1c kategorilerinin yığılı sütun grafiği (%).

rutin HbA1c tarama protokollerinin ve metabolik komorbidite yönetiminin önceliklendirilmesi gerektiğine işaret etmektedir.

5 Türkçe Epikriz Üzerinde Doğal Dil İşleme

Veri setindeki epikriz metni, klasik klinik dokümantasyon yapısında (yakınma, öykü, izlem, plan) yazılmış zengin bir bilgi kaynağıdır. İki tamamlayıcı NLP analizi gerçekleştirilmiştir.


5.1 TF-IDF ile Kanser Türüne Özgü Anahtar Terimler

Her kanser türünün tüm epikriz metinleri tek bir belge olarak birleştirilmiş ve 5 belge üzerinde TF-IDF vektörleştirilmesi yapılmıştır. Türkçeye özgü temel bir durdurma sözcüğü (*stopword*) listesi tanımlanmış, en az üç harfli yalnızca harf içeren tokenlar dikkate alınmıştır. Sonuçlar, terimlerin klinik olarak anlamlı sinyaller verdiğini göstermiştir: prostat için *psma*, over için *markerleri*, miyelom için *kür* (kemoterapi siklusu) gibi terimler ilk sıralarda yer almıştır.

5.2 Regex Tabanlı Semptom Çıkarımı

On adet sık görülen onkolojik semptom için Türkçe morfolojik varyantları yakalayan düzenli ifadeler tanımlanmıştır (*ağrı*, *bulantı*, *kusma*, *yorgunluk/halsizlik*, *ateş*, *iştahsızlık*, *kilo kaybı*, *nefes darlığı*, *kabızlık*, *ishal*). Şekil 3, semptom sıklıklarının kanser türüne göre dağılımını sunmaktadır.

Tüm gruplarda *ağrı* %95'in üzerinde gözlenmiştir; bu, ileri evre onkoloji popülasyonu için beklenen bir bulgudur. Ayırt edici sonuçlar şunlardır: bulantı ve kusma karaciğer ile miyelom hastalarında daha yüksektir; nefes darlığı prostat (%47) ve meme (%42) kanserinde öne çıkmaktadır (kemik metastazı veya plevral efüzyon hipoteziyle uyumlu); kabızlık özellikle multipl miyelom ve prostat kanserinde belirgindir (opioid kullanımı ve hiperkalsemi olası nedenler arasındadır).



Şekil 3: Epikriz metinlerinde semptom yüzdeleri (kanser türüne göre).


6 Baseline Sınıflandırıcılar

Yalnızca rutin laboratuvar (`_mean` özetleri), yaş ve cinsiyet özellikleriyle, beş sınıflı kanser türü tahmini görevinde iki baseline model değerlendirilmiştir. Eksik değerler medyan ile doldurulmuş, lojistik regresyon için ayrıca standart ölçeklendirme uygulanmıştır. Tüm değerlendirmeler, `random_state=42` ile 5-katlı tabakalı çapraz doğrulama (Stratified K -Fold) altında yapılmıştır.

Tablo 3: 5-katlı çapraz doğrulama performansı (rastgele $\approx$ %20).

Model	Doğruluk (ortalama $\pm$ s.s.)	Makro F1
Lojistik Regresyon	0.684 ± 0.027	0.684
Rastgele Orman	0.712 ± 0.031	0.710

Rastgele Orman, rastgele tahminin yaklaşık 3.5 katı bir doğruluk elde etmiştir. Sınıf bazında en yüksek F1 skoru meme kanserinde (0.90) gözlenmiştir; bunun temel nedeni cinsiyet özelliğinin neredeyse tek başına meme kanserini diğer gruplardan ayırt etmesidir. En zor sınıf multipl miyelom ($F1 = 0.53$) olmuştur; karaciğer kanseri ile karışmaktadır, çünkü her iki grup da bozuk hepatik panel sergileyebilmektedir. Şekil 4 hata matrislerini ve özellik önemlerini göstermektedir.



Şekil 4: Modellerin hata matrisleri ve Rastgele Orman özellik önemleri.

En önemli özellikler sırasıyla *klor ortalaması*, *cinsiyet*, *AST*, *GGT* ve *yaş* olarak bulunmuştur. Hepatobilier enzimlerin (AST, GGT) ön sıralarda yer alması, modelin biyolojik olarak anlamlı sinyalleri yakaladığının göstergesidir.

7 Klinik Uygulama Önerileri

Bu basit baseline'lerden yola çıkarak şu uygulama fikirlerini önermekteyiz:

- **Otomatik metabolik tarama tetikleyicisi:** Prostat ve meme kanseri tanısı alan hastalar için elektronik hasta dosyasında HbA1c isteminin otomatik önerilmesi.
- **Türkçe semptom etiketleyici:** Epikriz girişi sırasında semptomları gerçek zamanlı olarak yapısal etiketlere çeviren ve standardizasyonu artıran bir NLP eklentisi.
- **Lab tutarlılık uyarı sistemi:** Mevcut tanı ile uyumsuz lab paterni durumunda klinisyene karar destek uyarısı veren bir modül.

8 Sınırlamalar

Çalışmanın temel sınırlamaları şunlardır: (i) örneklem 500 hasta ile sınırlıdır ve veri setinde sentetik üretim izleri mevcut olabilir; (ii) lab değerleri zaman serisi içermesine rağmen yalnızca özet istatistikler kullanılmıştır; (iii) HbA1c için "Bilinmiyor" oranı (%11–%36) kanser türüne göre değişmektedir, bu da seçici olmayan veri eksikliği varsayımını ihlal edebilir; (iv) Türkçe NLP işleme minimal düzeyde tutulmuştur; üretim ortamında Zemberek veya BERTurk gibi morfolojik/sözcüksel kaynaklar kullanılmalıdır.

9 Sonraki Adımlar

1. Lab zaman serilerinden trend tabanlı özellikler (eğim, varyasyon) çıkarmak.
2. Epikrizden BERTurk tabanlı varlık adı tanıma (NER) ile yapısal bilgi çıkarımı.
3. ölüm tarihi sütunu üzerinden hayatta kalma analizi (Kaplan-Meier, Cox regresyonu).
4. ATC kod hiyerarşisi kullanılarak ilaç temelli terapi profilleri ve kümeleme.

10 Tekrar Üretilbilirlik

Tüm kod tabanı GitHub deposunda **stage1** dalında, on ayrı *conventional commit* olarak yayımlanmıştır:

<https://github.com/ahmeterdempmk/datamedx-hackathon-2>

Yeniden üretmek için:

```
pip install -r requirements.txt
python src/eda.py
python src/hba1c_analysis.py
python src/nlp_epikriz.py
python src/model_baseline.py
```

Takım: CatBoost Baseline

- **Ahmet Erdem Pamuk** (Kaptan) — Mustafa Hakan Güvençer Fen Lisesi, Ankara
ahmeterdempmk@gmail.com
- **Hamit Tuğrul Arslan** — İstanbul Teknik Üniversitesi Mesleki ve Teknik Anadolu Lisesi, İstanbul
- **Ömer Kay** — Özel Çağdaş Eğitim Anadolu Lisesi, İzmir